アジャイルワーク2

ニューラルネットワーク
重みデータ圧縮に関する実験計画書

学籍番号　25G1017
氏名　岩澤大心

作成日：2026年10月9日

改訂日：2026年10月16日

提出期限：2026年10月16日（金）

目次

1 実験の目的 **1**
1.1 データ圧縮が必要な理由 1
1.2 検証する仮説 1

2 実験の理論 **1**
2.1 圧縮方式の調査と選択 1
2.2 ネットワークのデータ量 2
2.3 閾値による枝刈り 2
2.4 疎行列の格納方式 3
2.5 8 bit量子化 3
2.6 評価指標 4

3 実験方法 **4**
3.1 実験条件 4
3.2 学習・検証・最終評価データの分離 5
3.3 実験条件の一覧 6
3.4 プログラムの実装手順 6
3.5 性能確認方法 7
3.6 方式と閾値の選択基準 8
3.7 結果の記録様式 8

4 予想される結果と問題発生時の対応 **9**

1 実験の目的

本実験の目的は，カラーチャートの読み取り値を補正するニューラルネットワークについて，Arduino上で使用する重みデータを圧縮し，限られたメモリ内で推論精度を保ったまま 隠れ層の次元数を拡大できる条件を明らかにすることである．

1.1 データ圧縮が必要な理由

対象ネットワークは入力3次元，隠れ層2層，出力3次元である．授業資料では，隠れ層60次元は コンパイル・実行が可能である一方，70次元ではメモリ不足によるコンパイルエラーが確認されている． 隠れ層を大きくすると表現能力の向上が期待できるが，第2層の重み数は次元数の二乗で増加するため， 32 bit浮動小数点数のまま全要素を保存する方法には限界がある．

したがって，Arduinoの限られたメモリに，より大きな隠れ層を持つモデルを搭載するには， 推論への影響が小さい情報を削減し，重みデータを小さくする必要がある．ただし，容量だけを 小さくしても補正精度や実行速度が大きく悪化すれば実用にならないため，データ量，精度，速度を 同時に測定し，圧縮方式を選ぶ必要がある．

そこで，L1正則化によって絶対値が小さくなった重みを0へ置き換える枝刈りと， 非ゼロ要素だけを保持するCSR（Compressed Sparse Row）形式を主方式として検討する． 比較方式として8 bit整数への量子化も評価する．隠れ層40，50，60次元において， 圧縮前後のモデル容量，Arduinoへの搭載可否，推論時間，平均二乗誤差（MSE）を同一条件で比較し， メモリ削減量と推論品質のトレードオフを定量化する．

1.2 検証する仮説

1. L1正則化後の絶対値が小さい重みは推論への寄与が小さいため，適切な閾値で0化してもMSEの増加は小さい．
2. 十分な疎性が得られれば，CSR形式は列番号等の付加情報を含めても密行列より小さくなる．
3. 8 bit量子化は疎性に依存せず約4分の1まで重みを削減できるが，量子化誤差によりMSEが増える可能性がある．

2 実験の理論

2.1 圧縮方式の調査と選択

適用候補として，絶対値の小さい重みを0にする枝刈り，COO・CSR等の疎行列形式， 重みを低ビット整数で表す量子化，および枝刈りと量子化を組み合わせるHybrid方式を 先行研究[2, 3, 5]に基づいて調査する． 各方式について，重み1要素当たりのデータ量，索引やスケール等の付加情報，Arduino上での 行列ベクトル積の実装可能性，期待される計算量，推論誤差を比較する．

本実験では，L1正則化による係数縮小[1]を利用でき，行単位の積和演算にも適する 枝刈り+CSRを主方式として選ぶ．一方，十分な疎性が得られない場合にも一定の削減効果を見込める INT8量子化を比較方式として選ぶ．計画段階では一方に確定せず，両方式を同一条件で実装・測定し， 容量，MSE，推論時間の選択基準に従って最終方式を決定する．どちらか一方に決められない場合は， 両方式の結果と適用条件を記録する．

2.2 ネットワークのデータ量

隠れ層の次元数をHとすると，各層の重み行列は $H \times 3$，$H \times H$，$3 \times H$である．順伝播は

$$\boldsymbol{h}_1 = \mathrm{ReLU}(W_1 \boldsymbol{x} + \boldsymbol{b}_1), \tag{1}$$
$$\boldsymbol{h}_2 = \mathrm{ReLU}(W_2 \boldsymbol{h}_1 + \boldsymbol{b}_2), \tag{2}$$
$$\boldsymbol{y} = W_3 \boldsymbol{h}_2 + \boldsymbol{b}_3 \tag{3}$$

によって計算される．パラメータ数は

$$N_{\mathrm{weight}} = H^2 + 6H, \tag{4}$$
$$N_{\mathrm{bias}} = 2H + 3, \tag{5}$$
$$N_{\mathrm{total}} = H^2 + 8H + 3 \tag{6}$$

となる．すべてを`float`（1要素4 byte）で保持した場合のデータ量は $B_{\mathrm{dense}} = 4N_{\mathrm{total}}$ byteである．理論値を表1に示す.

表 1: 密形式で保持した場合のパラメータ量（配列管理情報を除く）

H	重み数	バイアス数	合計要素数	FP32データ量 [byte]
40	1,840	83	1,923	7,692
50	2,800	103	2,903	11,612
60	3,960	123	4,083	16,332
70	5,320	143	5,463	21,852
100	10,600	203	10,803	43,212
200	41,200	403	41,603	166,412

この値以外にも，プログラム本体，入出力用配列，スタック等がArduinoのメモリを使用する． 本実験では隠れ層出力をFP32配列2本で保持する設計とし，その作業領域は $8H$ byte（$H = 60$では480 byte）となる．さらに，6×6画素のRGB値を 各成分1 byteで保持する場合，画像配列だけで108 byteを使用する． ビルド結果に表示されるRAM使用量は通常，グローバル変数等の静的領域であり， ローカル配列を含むスタックや動的確保領域をすべて含むとは限らない． フラッシュ使用量，静的RAM使用量，推論用作業配列の容量を区別して記録し， 実機での連続推論も確認して搭載可否を判断する．

全方式で重み配列とバイアスを読み取り専用として扱い，宣言の修飾子と配置方針を統一する． ただし，`const`を付けた配列の配置先と読出方法はボード・ツールチェーンに依存するため， 必ずフラッシュへ配置されるとは仮定しない．実験開始時に対象ボードの配置を確認し， 必要な読出方法を全方式でそろえる．モデル容量は重み，バイアス，索引，スケールの各配列の`sizeof`の合計で求め，配置やパディングを含むビルド全体の使用量と区別する．

2.3 閾値による枝刈り

学習後の重みwに閾値τを適用し，

$$\widetilde{w} = \begin{cases} 0 & (|w| < \tau), \\ w & (|w| \geq \tau) \end{cases} \tag{7}$$

とする．0となった割合（疎性）Sは，全重み数をN，非ゼロ重み数をKとして

$$S = 1 - \frac{K}{N} \tag{8}$$

で求める．本実験では$\tau = 0$を非圧縮の基準とし，$\tau \in \{0.001, 0.005, 0.01, 0.02, 0.05\}$を候補にする． 0.01は候補値の一つであり，固定値とはせず，MSEと容量の両方から選ぶ．

バイアスは要素数が少なく，0化による削減効果が小さいため，主実験ではFP32のまま保持する． これにより，圧縮による変化を重み行列に限定する．

2.4 疎行列の格納方式

$m \times n$行列にK個の非ゼロ要素がある場合，COO形式は値，行番号，列番号を列挙する． 一方，CSR形式は値配列，列番号配列，各行の開始位置を表す行ポインタ配列を使用する．CSRは疎行列ベクトル積で広く用いられる格納形式である[4]． $H \leq 200$では行・列番号を`uint8_t`，行ポインタを`uint16_t`で表現できるため， 理論データ量は概ね

$$B_{\mathrm{COO}} = (4 + 1 + 1)K = 6K, \tag{9}$$

$$B_{\mathrm{CSR}} = (4 + 1)K + 2(m + 1) \tag{10}$$

となる．3層分のCSR配列とFP32バイアスを合計すると

$$B_{\mathrm{CSR,total}} = 5K + 12H + 24 \tag{11}$$

byteである．したがってCSRが密形式より小さくなる目安は

$$K < \frac{4H^2 + 20H - 12}{5} \tag{12}$$

となる．CSRでは行番号を要素ごとに保存しないため，本実験のような行列積に適している．上式のKは3層分の非ゼロ重み数の合計である． 配列間のアラインメント等はビルド全体の使用量に影響し得るため，最終的には 各配列の`sizeof`の合計とビルド結果の両方で確認する．CSRが密形式より大きくなる条件では採用しない．

CSR形式の行列ベクトル積は次のように実装する．

コード 1: CSR形式による1層分の行列ベクトル積（概略）

```
for (uint16_t row = 0; row < rows; ++row) {
    float sum = bias[row];
    for (uint16_t p = row_ptr[row]; p < row_ptr[row + 1]; ++p) {
        sum += values[p] * input[col_idx[p]];
    }
    output[row] = sum;
}
```

2.5 8 bit量子化

比較方式では，整数演算向け量子化の先行研究[5]を参考に，層ごとに対称量子化を行う． 層内の最大絶対値を$w_{\max}$として スケール$s = w_{\max}/127$を求め，

$$q = \mathrm{clip}\left(\mathrm{round}\left(\frac{w}{s}\right), -127, 127\right) \tag{13}$$

により重みを`int8_t`へ変換する．ただし，$w_{\max} = 0$の層では$s = 1$，全要素$q = 0$とし， ゼロ除算を避ける．丸めは最近傍とし，ちょうど中間の場合は0から遠い側へ丸める． 推論時はsqとして使用する．本実験のINT8は重みの格納形式のみを量子化し， 入力・中間出力・バイアス・積和演算はFP32とする． 必要な重みだけを積和演算時にFP32へ復号し，全重みをFP32配列へ展開しない． したがって，全整数による推論や速度向上を前提とせず，復号の時間も含めて測定する． 重み1個を4 byteから1 byteへ削減でき，各層に4 byteのスケール値を追加する． 3層分とFP32バイアスを合わせた理論データ量は$H^2 + 14H + 24$ byteである． バイアスはFP32のままとする．量子化は疎性が低い場合にも有効である一方， スケールの選び方や丸め誤差がMSEへ影響する．

2.6 評価指標

評価用カラーチャートの色数をN，色iの正解RGB値を$\boldsymbol{t}_i$， 推論値を$\boldsymbol{y}_i$とすると，MSEを

$$\mathrm{MSE} = \frac{1}{3N} \sum_{i=1}^{N} \sum_{c \in \{R,G,B\}} (y_{i,c} - t_{i,c})^2 \tag{14}$$

とする．Nは実際に用いる評価チャートの色数であり，3×3の場合は$N = 9$である．ニューラルネットワークへの 入出力は0.0–1.0へ正規化する一方，最終評価では従来どおり0–255のRGB値へ戻して P3形式のPPM画像を生成し，配布済みの`mse_calculator.html`で 評価チャートと同じ寸法・色順の基準PPM画像と比較する．学習に使用したチャートは 最終評価に流用せず，基準画像の対応とRGB尺度を確認する．全条件で同じ変換方法を使用する． 10回測定したMSEの平均を$\overline{\mathrm{MSE}}$とし，圧縮前からの絶対差と相対変化率を それぞれ

$$D_{\mathrm{MSE}} = \overline{\mathrm{MSE}}_{\mathrm{compressed}} - \overline{\mathrm{MSE}}_{\mathrm{dense}} \tag{15}$$

および

$$\Delta_{\mathrm{MSE}} = \frac{D_{\mathrm{MSE}}}{\overline{\mathrm{MSE}}_{\mathrm{dense}}} \times 100\ [\%] \tag{16}$$

で表す．基準の平均MSEが0の場合は相対変化率を算出せず，絶対差で評価する． MSEの単位は0–255のRGB値に基づく階調値の二乗である． また，モデルデータ削減率R_Bと圧縮比C_Bを

$$R_B = \left(1 - \frac{B_{\mathrm{compressed}}}{B_{\mathrm{dense}}}\right) \times 100\ [\%], \tag{17}$$

$$C_B = \frac{B_{\mathrm{dense}}}{B_{\mathrm{compressed}}} \tag{18}$$

とする．

3 実験方法

3.1 実験条件

独立変数，従属変数，統制条件を表2に示す．

表 2: 実験変数

分類	内容
独立変数	隠れ層次元H（40，50，60），圧縮方式（密FP32，枝刈り+CSR，INT8），枝刈り閾値τ
従属変数	MSE，MSE絶対差・相対変化率，疎性，モデルデータ量，削減率，コンパイル・書き込み・実行可否，RAM・フラッシュ使用量，推論時間
統制条件	学習データ，学習済み重み，評価チャート，黒・白校正手順，`SAMPLE_COUNT`，`RGB_FLASH_DELAY`，RGB尺度，測定治具，照明，チャート位置，紙の圧着，ソフトウェア版

使用ボードはArduino UNO R4 WiFiとする．主マイコンRA4M1のSRAMは32 KB（32,768 byte）， フラッシュメモリは256 KB（262,144 byte）である．推論はRA4M1側で実行し，WiFi通信用ESP32-S3のメモリはモデルの格納先に含めない． カラー読取用センサ・光源，固定治具，遮光部材とPCを使用する． 実験開始時にArduino IDE・ボードコア・コンパイラ・

Python・PyTorchのバージョンと， ビルド表示上の利用可能メモリ量を確認して実験記録へ記載し，以後の比較では固定する． 授業資料の60次元で実行可，70次元でコンパイル不可という結果は参考とし， 使用する実機でもDense-FP32の搭載限界を確認する．

本実験の学習条件は，損失関数をMSE，最適化手法をAdam，学習率を0.01， L1正則化係数を10^{-6}，学習回数を50,000 epochとする．圧縮の影響だけを比較するため，各Hについて一度得た 同一の学習済み重みからすべての圧縮条件を生成し，圧縮条件ごとに再学習は行わない． 学習用データは，3×3の9色と，6×6で読み取った画像の上4行 （6×4の24色）を合わせた33組とする． RGBを0–255から0.0–1.0へ正規化して`train_L1_normalization.ipynb`へ入力する． 教師データは対応する基準画像から各色のRGB値を取得する．縮小には最近傍法を用い， 6×4の読取データには6×6の基準画像の上4行を対応させるなど，色の位置を一致させる． 読取ミスを学習しないよう，元のPPM画像を目視確認してから学習データへ変換する．モデル生成前にNumPyとPyTorchの乱数シードを42に固定し，学習はPCのCPU上で行う．データの並び順，学習済み重み，学習ログを保存する．次元ごとに1回の学習とし， 本実験の結論はその学習済みモデルに対する圧縮の影響に限定する．

3.2 学習・検証・最終評価データの分離

データの用途は次の3つに分け，ファイル名とチャート識別子で管理する．

1. **学習用：**上記33組を重みの学習に使用する．
2. **検証用：**学習に使用していない色を含む別チャートの読取値と正解RGB値を用意し， 枝刈り閾値と圧縮方式の選択に使用する．読取は独立した3回分を取得し，PC上の事前評価に用いる．
3. **最終評価用：**学習用・検証用と別のチャートを用い，可能であれば教員から配布を受ける． 比較する方式と各方式の設定（閾値等）を固定した後の実機評価だけに使用する．

検証用と最終評価用には，同じチャートを単に再読取したデータを用いず，色の組合せが異なるものを用いる． 別々のチャートを用意できない場合は，学習に用いない1枚の追加チャートの色を， 測定結果を見る前に検証用と最終評価用へ分割し，対応する色だけでMSEを計算する． その場合は色数，分割方法，同一チャート内の分割であるという制約を記録する． 現時点では追加チャートの入手可否は未確定のため，実験開始前に用意できるチャートと分割方法を確定する． 独立した検証・最終評価用の色を用意できない場合でも，実装・固定入力比較・容量・速度の確認を先行する． ただし，学習データでのMSEは参考値とし，独立データでの精度確認が完了したとは扱わない． 最終評価結果を見て同じ評価データで閾値を選び直すことはしない．

3.3 実験条件の一覧

表 3: 比較する方式

条件	重み表現	バイアス	目的
Dense-FP32	FP32密配列	FP32	圧縮前の基準
Pruned-Dense（PC確認）	枝刈り後のFP32密配列	FP32	枝刈り誤差とCSR実装誤差の切り分け
Prune-CSR	閾値枝刈り後のFP32値とCSR索引	FP32	小さい重みを除去した疎行列圧縮
INT8	層ごとの対称8 bit量子化	FP32	疎性に依存しない比較方式
Hybrid（任意）	枝刈り後のINT8値とCSR索引	FP32	必須実験完了後の追加検討

まずPC上で検証用データに対して全閾値を事前評価し，Arduino実機へ載せるPrune-CSR条件を 各Hにつき1条件へ絞る．Dense-FP32，選んだPrune-CSR，INT8の3方式を， 40，50，60次元でそれぞれ比較するため，実機測定は基本9条件となる． 授業課題として優先する圧縮前後のMSE比較を，容量・速度の測定と合わせて実施する． 40，50，60次元の比較が完了した後，70次元のDense-FP32と圧縮版で搭載可否を比較し， 容量に余裕があれば100次元を試す．200次元およびHybridは発展課題とし，必須条件の測定を優先する．

3.4 プログラムの実装手順

1. **基準モデルの作成：** $H = 40, 50, 60$について，3×3および6×4チャートから取得した 同一の正規化済み学習データを用いて学習する． Notebook側では単一の変数Hを3つのLinear層へ使用し，Arduino側の HIDDEN_SIZE1とHIDDEN_SIZE2も同じ値へ変更する．学習用・検証用・最終評価用のデータを分離し，最終評価用は選択段階で使用しない．

2. **PC上での圧縮候補生成：** Pythonで各重みに閾値を適用し，疎性，CSR理論容量，検証用データでの圧縮後MSEを計算する． PC上でもArduinoと同じ前処理・後処理を適用し，0–255のRGB値でMSEを求める． 同じ重みからINT8版も生成し，検証結果に基づいてCSRの閾値を決める．

3. **ヘッダファイルの出力：** 学習ノートブックが出力するmodel_parameters.hを基準とする． Dense-FP32では従来のweight_1[]–weight_3[]と bias_1[]–bias_3[]を出力する．Prune-CSRでは各層ごとに values[]，col_idx[]，row_ptr[]の3配列を出力し， それぞれ非ゼロ値，列番号，行開始位置を格納する． INT8ではint8_t重みと層ごとのスケールを出力する． 密形式とINT8では，重み要素数が$3H$，H^2，$3H$，バイアス要素数がH，H，3であることを検査する． CSRでは第l層の非ゼロ数をK_l，行数をm_lとして，値・列番号の配列長がK_l， 行ポインタの長さが$m_l + 1$であることを確認する．各層の配列には層番号を付け，名前の重複を避ける．

4. **Arduino推論処理の実装：** Dense，CSR，INT8の各行列ベクトル積関数を分離して実装する． 重みを出力ニューロン単位の行優先で参照し， 隠れ層1・2だけにReLUを適用する．出力層にはReLUを適用しない． normalizeInput()では，入力を (raw – black)/(white – black)で正規化して0–1へクリップする． outputTo255()では，出力を0–1へクリップし，255倍して四捨五入する． 黒・白校正値が同一で分母が0になる場合は校正不成立とし，再校正する． 圧縮方式を変更しても，この前処理・後処理とバイア

ス加算順序は変更しない． 配布プログラムの仕様も実装前に確認し，変更点を実験記録へ残す．

5. **単体確認：** PC上で枝刈り後の密行列とCSRから復元した行列が一致することを確認する． 同じ固定入力に対するPruned-DenseとPrune-CSRの出力を比較した後，PC版とArduino版の各層出力を比較する． CSRの行ポインタ先頭が0，終端がK_l，並びが非減少であること，列番号が列数未満であること， 復元後の行列形状，整数のオーバーフロー，添字範囲を確認する． 行列の復元一致と，浮動小数点演算による出力の近似一致を区別する． 各層出力は絶対誤差10^{-5}と相対誤差10^{-4}を目安に照合し，超過時は演算順と実装を調べる．

6. **ビルド・実行確認：** 各条件を同一ボード設定でクリーンビルドし，コンパイル可否，フラッシュ・静的RAM使用量を記録する． 書き込み後，固定入力に対する出力と推論時間を確認する．

3.5 性能確認方法

実装後の性能は，Arduinoへの搭載可否，フラッシュ・RAM使用量，推論時間，MSEによって確認する． 各Hの同一学習済み重みから作成したDense-FP32を圧縮前の基準とし，Prune-CSRとINT8を同一条件で比較する． ニューラルネットワークを用いない`batansyusei.ino`は参考条件として区別し，圧縮前の基準には用いない． 特にMSE測定では，照明，紙の圧着，位置ずれ，周辺光による変動を圧縮誤差と混同しないため， 次の手順を用いる．

1. 学習に使用していない同一の評価用カラーチャートを全条件で使用する．
2. 配布の読取プログラムを基に，黒，白の順に校正してから各画素を読み取る． 使用するボタン割当ては配布コードで確認し，全方式で統一する． 書き込み後は毎回同じ位置・手順で校正し，得られた値と時刻を記録する．
3. 1色のセンサ値は`SAMPLE_COUNT`=10回の平均とし，RGBの読取時間ずれを抑えるため，`RGB_FLASH_DELAY`=10 msに固定する． センサ，光源，遮光，紙の固定治具，チャート位置を変えず，測定前に光源を60秒間点灯して安定させる．
4. 評価チャートのN色を同じ順序で読み取り，各回についてチャートと同じ寸法のP3形式PPM画像を保存する． `mse_calculator.html`へ評価チャートに対応する基準PPM画像と読取画像を入力してMSEを記録する． 色の一部を最終評価用に分けた場合は，指定した色のRGB値を抽出して同じMSEの式で計算する．
5. 各Hについて3方式を1回ずつ測ることを1ブロックとし，10ブロック実施する． 測定順序はDense–CSR–INT8，CSR–INT8–Dense，INT8–Dense–CSRの順で巡回し，時間変化の偏りを抑える． 基本9条件，各10回の合計90回分の測定を行う．
6. 各回のMSEを保存し，平均，標本標準偏差（分母$n-1$），最小値，最大値を求める． 同一ブロック内の圧縮版とDense版のMSE差についても平均と標準偏差を求める． 測定ばらつきだけから有意差があるとは断定せず，差の大きさと変動を併記する．

物理的な読取誤差と圧縮誤差を分けるため，最終評価用のセンサ生値と黒・白校正値を保存し， 同じ保存済み入力を各方式へ与える固定入力比較も行う． これは方式決定後の確認とし，この結果で閾値を選び直さない．

推論時間は`micros()`で計測する．同じ保存済み入力列について10回のウォームアップ後，100回連続実行し，合計時間を100で割る．これを5組繰り返し，1推論当たりの時間の平均と標準偏差を求める． 計測区間は正規化済み入力からネットワーク出力までとし，CSRの索引参照，INT8の復号，ReLUを含める． センサ読取，待機，RGB画像への変換，シリアル出力は除外する． 出力のチェックサムを計測後に表示し，コンパイラによる未使用演算の削除を防ぐ．

3.6 方式と閾値の選択基準

PC上の閾値選択では，検証用データの平均MSE増加率が5%以下で，CSR容量が密形式未満となる候補から， CSR容量が最小の閾値を選ぶ．Denseの検証MSEが0の場合は，圧縮後も0であることを条件とする． 同容量なら検証MSEが小さい候補を選ぶ．該当候補がなければ CSR は採用条件を満たさないと記録し，容量が最小となる閾値を診断用に実機比較する． 実機比較を終えた後，方式の採否は次の優先順位で判断する．

1. **必須条件：**Arduinoでコンパイル，書き込み，推論が正常に完了する．
2. **品質条件：**暫定基準として，圧縮前に対する平均MSEの増加率を5%以下とする． 基準の平均MSEが0の場合は，圧縮後も0となることを条件とする． さらに絶対差と反復測定のばらつきを併記する．
3. **容量条件：**品質条件を満たす候補のうち，使用ボードで搭載を制約するメモリの使用量が 小さいものを優先し，モデル容量と静的RAM・フラッシュ使用量を併記する．
4. **速度条件：**推論時間がDense-FP32より20%を超えて増加する場合は，容量削減との利得を比較し，採否を再検討する．
5. **実装条件：**容量とMSEが同程度なら，配列数が少なく，誤添字やオーバーフローを防ぎやすい方式を選ぶ．

5%および20%は本計画で比較を行うための暫定基準であり，授業で指定された値ではない． 最終判断では，Dense-FP32，Prune-CSR，INT8の「MSE–容量–速度」を図示し， いずれか一指標だけでなくPareto関係を確認する．CSRの索引を含む実容量が密形式以上なら，その閾値ではCSRを不採用とする． 最終評価で品質条件を満たさなかった方式は，その結果を含めて報告する． やむを得ず閾値を再調整する場合は，当該データを検証用として扱い，新しい最終評価データを用意する．

3.7 結果の記録様式

各条件について，表4と表5を同じ条件IDで対応させて記録する． 条件IDにはH，方式，閾値，乱数シードを含める．結果欄は測定後に記入し， コンパイル・書き込み・実行はそれぞれ可／不可，未実施は未実施と記録する．

表 4: 容量・メモリ使用量の記録表

H	方式	τ	疎性 [%]	モデル [byte]	削減率 [%]	静的RAM [byte]	Flash [byte]
40	Dense	0					
40	CSR						
40	INT8	–	–				
50	Dense	0					
50	CSR						
50	INT8	–	–				
60	Dense	0					
60	CSR						
60	INT8	–	–				

表 5: 動作・品質・速度の記録表

H	方式	コンパイル／書込／実行	平均MSE $\pm s$	D_{MSE}	Δ_{MSE} [%]	推論時間 平均$\pm s$ [μs]
40	Dense					
40	CSR					
40	INT8					
50	Dense					
50	CSR					
50	INT8					
60	Dense					
60	CSR					
60	INT8					

各回のMSE，最小値・最大値，同一ブロック内のMSE差，圧縮比，作業配列容量， 時間計測5組の生データは別の測定CSVへ保存する．INT8の疎性は圧縮方式の選択に使用しないため， 表中では対象外とする．ビルドや書き込みに失敗した場合も行を削除せず，失敗段階とログを残す.

4 予想される結果と問題発生時の対応

L1正則化によって第2層を中心に絶対値の小さい重みが多くなり，適切な閾値ではMSEを大きく 悪化させずにCSR容量を削減できると予想する．ただし疎性が低い場合，CSRは索引の分だけ Dense-FP32より大きくなる．INT8は一定の削減効果が得られるが，外れ値にスケールが支配されると 小さい重みの量子化誤差が増える可能性がある．

PC上の検証で品質条件を満たす閾値が得られない場合は，小さい閾値を優先して影響を確認し， 全候補のMSEと容量を記録する． CSRの容量削減が得られない場合はINT8を主候補とする．INT8のMSEが大きく悪化する場合は， 16 bit量子化または層単位から行単位へのスケール変更を検討する． 実測MSEのばらつきが圧縮前後の差より大きい場合は，固定治具と遮光を再確認し， 各方式とも追加で10ブロック測定し，合計20回へ増やす．追加分だけで結論を選ばず，全測定を集計する． 100次元以上が搭載できない場合でも，40–60次元の必須比較を完了させ， 容量計算から障害原因を説明する．

参考文献

[1] R. Tibshirani, “Regression Shrinkage and Selection via the Lasso,” Journal of the Royal Statistical Society: Series B, vol. 58, no. 1, pp. 267–288, 1996.

[2] S. Han, J. Pool, J. Tran, and W. J. Dally, “Learning Both Weights and Connections for Efficient Neural Networks,” Advances in Neural Information Processing Systems 28, pp. 1135–1143, 2015.

[3] S. Han, H. Mao, and W. J. Dally, “Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding,” International Conference on Learning Representations (ICLR), 2016.

[4] N. Bell and M. Garland, “Implementing Sparse Matrix-Vector Multiplication on Throughput-Oriented Processors,” Proceedings of the Conference on High Performance Computing Networking, Storage and Analysis, Article 18, pp. 1–11, 2009.

[5] B. Jacob et al., “Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference,” Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 2704–2713, 2018.