枝刈り・CSRによる色補正モデルの圧縮

アジャイルワーク2　実験報告書草稿（確認用抜粋）

25G1017　岩澤大心

記録整理日：2026年11月13日

1　本稿の範囲

本稿は完成版から一部を省略した確認用草稿である．実施済みの実験に基づき，目的・理論・実験方法と，新規10回のMSE集計までを掲載する．

2　目的

Arduino上の色補正モデルについて，枝刈り＋CSRによる保存容量と推論時間の削減効果，および補正精度への影響を調べる．Denseに対するMSE増加5%以下を精度維持の条件とし，MSE300以下も別に判定する．

同じHのDenseと枝刈り＋CSRへ同一入力を与えて比較した．当初計画の40・50・60次元から，実施条件を40・60・80・100へ変更した．H50は未実施である．

3　比較の構成

図1のように，1回のセンサ読取から得たRGBを両方式へ入力した．4種類のHと2方式を組み合わせ，比較条件は8個とした．

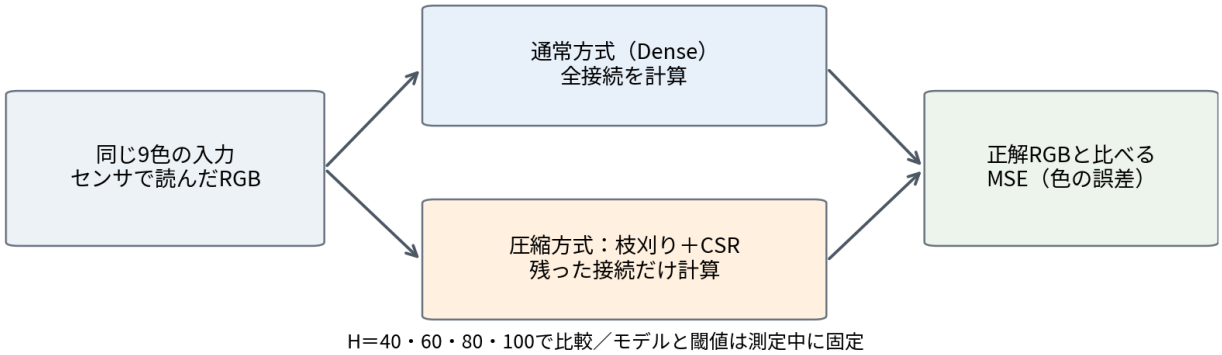


図1　同一入力による比較

用途	データ・操作
学習	過去の実測135行：3×3チャート111行，6×4チャート24行
閾値選択	別の8×8チャートを2回読んだ128入力と，学習内9入力
精度測定	学習にも使用した3×3チャートを新しく10回読取，計90入力
速度測定	保存済み実測9入力を実機で反復再生

用途	データ・操作
メモリ比較	各モデル単独の8条件をコンパイル

新規10回の入力は学習・閾値選択へ加えていない．ただし，色自体は学習時と同じであり，独立した未見チャートによる最終評価ではない．

4　仕組みと計算方法

4.1　ネットワークと学習

ネットワークは3–H–H–3の全結合構造とした．入力を x，重みを W，バイアスを b とすると，

$$
\begin{aligned}
h_1 &= \mathrm{ReLU}(W_1 x + b_1),\\
h_2 &= \mathrm{ReLU}(W_2 h_1 + b_2),\\
y &= W_3 h_2 + b_3.
\end{aligned}
$$

隠れ層にReLUを用い，出力層は線形とした．学習には，重み付きSmooth L1損失[5]と，バイアスを除く重みへのL1正則化[1]を用いた．

$$
\mathcal{L} = \frac{1}{\sum_{i=1}^{M} a_i} \sum_{i=1}^{M} \frac{a_i}{3} \sum_{c\in\{R,G,B\}} \ell_\beta(\hat{y}_{i,c} - t_{i,c}) + 10^{-6} \sum_{\ell=1}^{3} \sum_{j,k} |(W_\ell)_{jk}|,
$$

$$
\ell_\beta(e) = \begin{cases} e^2/(2\beta) & (|e| < \beta),\\ |e| - \beta/2 & (|e| \ge \beta), \end{cases} \qquad \beta = 0.05
$$

$M = 135$ は学習行数，$a_i > 0$ は行ごとの重要度，$\hat{y}$ は予測，t は正解，c はRGB成分を表す．学習時の尺度は0〜1とした．ℓ は層番号，jとkは行列内の位置である．L1項は全3層の重みの絶対値を合計し，小さい重みを作る方向に作用する．学習損失と，評価時の整数RGBのMSEは区別する．

4.2　枝刈りとCSR

枝刈り[2]では $|w| < \tau$ の重みを0にし，バイアスは保持した．残った重みを，値・列番号・行開始位置の3配列からなるCSR[3]へ変換した．保存・計算対象を非ゼロ重みに限定する．3層の非ゼロ重み数をKとすると，疎性Sは次式である．

$$
S = 1 - \frac{K}{H^2 + 6H}
$$

4.3　メモリ容量の手計算

Denseの重み数は $N_w = 3H + H^2 + 3H$，バイアス数は $N_b = 2H + 3$ である．FP32は1個4 byteなので，

$$
B_{\mathrm{Dense}} = 4(N_w + N_b) = 4(H^2 + 8H + 3) \quad [\mathrm{byte}]
$$

となる．CSRは非ゼロ重みK個をFP32，列番号をuint8，行開始位置をuint16で保存する．行位置は3層の行数に各終端を加えた $2H + 6$ 個となる．バイアスを全て残すと，

$$
\begin{aligned}
B_{\mathrm{CSR}} &= 4K + K + 2(2H+6) + 4(2H+3) \\
&= 5K + 12H + 24 \quad [\mathrm{byte}]
\end{aligned}
$$

H60では重み3,960個，バイアス123個，枝刈り後K=1,141個なので，

$$
\begin{aligned}
B_{\mathrm{Dense}} &= 4(60^2 + 8\cdot 60 + 3) = 16,332, \\
B_{\mathrm{CSR}} &= 4,564 + 1,141 + 252 + 492 = 6,449, \\
R_B &= 100(1 - 6,449/16,332) = 60.51\%
\end{aligned}
$$

全HのCSR配列の内訳を示す．単位はbyteである．

H	非ゼロ重み	列番号	行位置	バイアス	合計byte
40	1,880	470	172	332	2,854
60	4,564	1,141	252	492	6,449
80	6,596	1,649	332	652	9,229
100	9,496	2,374	412	812	13,094

配列容量が減る条件は $5K < 4H^2 + 20H - 12$ で，採用した4条件は全て満たす．この計算は数値配列のみを対象とし，構造体・アラインメント・Arduinoコア等を含むFlash全体はIDE表示で別に評価した．

4.4 評価指標

出力を0〜1へクリップし，255倍して四捨五入した整数RGBで評価した．9色の補正値 y と正解 t から，MSEを次式で求めた．

$$
\mathrm{MSE} = \frac{1}{27}\sum_{i=1}^{9}\sum_{c\in\{R,G,B\}}(y_{i,c} - t_{i,c})^2
$$

各回のMSEを m_r とし，10回平均と標本標準偏差（SD）を算出した．

$$
\overline{m} = \frac{1}{10}\sum_{r=1}^{10} m_r, \qquad s_m = \sqrt{\frac{1}{9}\sum_{r=1}^{10}(m_r - \overline{m})^2}
$$

MSE・標本SD・対応差は小数第2位まで表示し，第3位以降を切り捨てる．集計・増加率の計算には切り捨て前の値を使用する．

同じ回の差を $d_r = m_{r,\mathrm{CSR}} - m_{r,\mathrm{Dense}}$ とした．MSE増加率は $100(\overline{m}_{\mathrm{CSR}}/\overline{m}_{\mathrm{Dense}} - 1)$ とし，各回の割合の平均は使わない．容量Bと時間Tの削減率は，それぞれ $100(1 - B_{\mathrm{CSR}}/B_{\mathrm{Dense}})$，$100(1 - T_{\mathrm{CSR}}/T_{\mathrm{Dense}})$ で求めた．

5 実験方法

独立変数はHと方式，従属変数はMSE・モデル配列容量・Flash・静的RAM・推論時間とした．同じHでは，元モデル・入力・RGB丸め・ボード・計時条件をそろえた．H間では追加学習前の重みも異なる．

5.1 装置と実行環境

項目	実施条件
ボード	Arduino UNO R4 WiFi
主マイコン・クロック	Renesas RA4M1，48 MHz
公称Flash／SRAM	262,144／32,768 byte
センサ	A0へ接続した光センサ，型番未確認
LED	R:D8，G:D6，B:D7，analogWrite 255／0
読取設定	各チャンネル10サンプル平均，サンプル間2 ms，点灯後10 ms待機
操作	シリアル9600 bps，外付けD2/D3ボタンは不使用
PC環境	Mac，Jupyter Notebook
最終学習・集計	クラウドPython 3.12，PyTorch 2.8.0，NumPy 2.3.5
実機コンパイラ	7.2.1 20170904，ARM/embedded-7-branch revision 255204
Arduino IDE・コア	版番号未記録，コンパイラ文字列を保存

紙は手で支え，照明を同じ状態に保つ手順で測定した．照度・距離・角度の定量記録はない．

5.2 学習データと正解画像

実測135行を全て保持し，配布Notebookの見本入力は実測として追加しなかった．正解画像の取り違えを修正し，最終V10では3×3分111行の教師値と評価を，先生指定の元の `result.ppm` へ統一した．灰色の正解は(127,127,127)である．6×4分24行は元のNotebookの教師値を保持したが，別の先生指定PPMとの照合はできていない．旧CMYK基準のMSEは結果へ混在させない．

各Hは同じHのV9重みから40,000 epoch追加学習した．seed42，Adam，cosine学習率0.0005→0.000005とし，色・校正グループや過去入力の整合度に基づく正の行重要度を使用した．

データ拡張として，3×3入力の50%にRGB別gain 0.75〜1.30とoffsetを加えた．灰・白には30%の確率で共通gain 0.5〜1.15を適用した．offset幅は学習入力間の距離から定め，設定と行重要度をコード・CSVへ保存した．これは学習時の変換であり，物理測定の追加ではない．

5.3 実装アルゴリズムとソースコード

PCで学習・閾値選択・枝刈り・CSR変換を行い，Dense重みとCSR配列を数値ヘッダへ出力した．Arduinoでは共通入力から両方式を計算した．重みの形式は両方式ともFP32とした．

CSR変換では各層を行順に走査し，非ゼロ重みを `values`，列番号を `col` へ格納した．`row` は各行の開始位置と配列終端を示す．列番号は昇順とし，加算順序を元の行列にそろえた．実際の `teacher_compare_v10.ino` の関数を示す．

```
void sparseLayer(const comparison_models::SparseLayer &layer,const float *input,float *output,bool
↪  relu) {
  for(int r=0;r<layer.rows;r++) {
    float value=layer.bias[r];
    for(uint16_t k=layer.row[r];k<layer.row[r+1];k++) value+=layer.values[k]*input[layer.col[k]];
    output[r]=(relu && value<0)?0:value;
  }
}
```

各行はバイアスから開始し，row[r] から row[r+1] の手前までの非ゼロ重みと，col[k] に対応する入力の積を加算する．隠れ層のみReLUを適用する．comparison_models::predict() は条件番号に応じてDenseまたは3層のCSR計算を呼び出す．中間値は2本の作業配列に保持する．

新規読取では normalizeInput() で正規化・クリップし，inferAll() で全8条件を計算する．出力を整数RGBへ変換し，PPMとMSEを出力する．

validIndices() で行位置の単調性・終端・列範囲を，selfCheckAll() で固定入力に対する出力を検査した．CSR変換の正しさは枝刈り後のDense計算と照合し，精度への影響は枝刈り前のDenseとのMSE差で評価した．

学習は train.py，候補比較は select_compression.py，追加条件による閾値固定は finalize_compression.py，ヘッダ出力は build_program.py を使用した．受領ログは record_fresh_capture.py，単独ビルド表示は record_single_model_memory.py で検算・集計した．

5.4　閾値選択

学習済み重みの絶対値について，隣接する異なる値の中間を候補とし，候補数は固定しなかった．検証128入力でMSE増加5%以下かつDenseより小容量となり，学習内V8の9入力でもMSE300以下となる候補から最小容量のものを選んだ．新規10回の開始前に重み・閾値を固定した．

下表は選択に使用した入力での結果である．検証2回目には異なる6色が同じ0入力になる問題があり，選択は暫定とした．

H	検証Dense MSE	検証CSR MSE	変化率	学習内V8の9入力CSR MSE
40	5012.20	4715.84	-5.91%	277.51
60	5226.80	5292.58	+1.26%	260.18
80	5135.43	4553.44	-11.33%	259.25
100	5237.21	4632.38	-11.55%	290.37

5.5　紙の新規10回読取

TEACHER_FRESH_V10 で，各回に黒b・白wを登録した．各RGBの読取値vから $(v-b)/(w-b)$ を求め，0〜1へクリップして入力とした．

赤・緑・青・黄・水色・紫・黒・灰・白の順に紙を当て直し，rを各1回送信した．同じ新規入力を全8モデルへ与え，9色終了後に8個のMSEと8枚のPPMを保存した．nで次回の校正へ進み，CAPTURE=1〜10を実施した．反復単位は9色の読取1回であり，内部10サンプル平均は反復回数に数えない．

RAW・黒白校正値・正規化入力・モデル識別値・閾値・PPMを全回保存した．第2回は高MSEだったが，操作ミスの申告はなく，全10回を集計した．除外した回はない．

5.6　速度と容量の測定

TEACHER_RESULT_COMPARE_V10 で保存済み実測9入力を巡回した．各モデル10回のウォームアップ後，100推論×5組を計時し，Dense先行とCSR先行を交互にした．micros() [4]の差を100で割り，1推論当たりの時間を求めた．

```
uint32_t timeModel(int model,int group,double &checksum) {
  float output[3];checksum=0;
  uint32_t begin=static_cast<uint32_t>(micros());
  for(int call=0;call<100;call++) {
    int input=(group*100+call)%comparison_models::BENCHMARK_INPUT_COUNT;
    comparison_models::predict(model,comparison_models::BENCHMARK_INPUTS[input],output);
    checksum+=output[0]+output[1]+output[2];
  }
  return static_cast<uint32_t>(micros())-begin;
}
```

計時区間は推論・入力選択・チェックサム加算を含み，センサ読取・シリアル出力・MSE計算を除く．新規10回の読取時間や，推論関数単体の時間とは異なる．

容量は，重み・バイアス・CSR索引の数値配列，8条件入りプログラム全体，単独モデル入りプログラム全体を分けて評価した．単独比較は memory_probe_v10 で8条件を各1回コンパイルし，Arduino IDEのFlash・静的RAM表示を記録した．共通の初期化・推論呼出し・シリアル出力を含み，センサ読取・MSE計算を除く．単独版の実行確認，IDE・コア版とバイナリは未記録である．

5.7　計画から変更した実装とその理由

学習データと損失． 読取・校正による入力変動に対応するため，33組から追加実測を含む135行へ増やし，gain・offsetによるデータ拡張を導入した．大きな残差の影響を抑えるため，MSE損失から重み付きSmooth L1へ変更した．全行を正の重要度で残し，評価にはMSEを用いた．

正解画像と選択条件． Notebook表示と先生指定 result.ppm のRGBが異なっていたため，3×3の教師値と評価を指定PPMへ統一した．検証MSE増加5%以下に加え，学習内9入力でMSE300以下を閾値選択の条件とした．新規10回の結果による再選択は行っていない．

次元と配置． Hの増加による容量・速度・精度の変化を調べるため，40・60に80・100を追加し，50は未実施とした．モデルをconst配列としたため，授業例の搭載可否をそのまま適用できない．H100のDense配列43,212 byteに対し静的RAMは6,764 byteであり，配列容量と静的RAM表示は一致しない．リンカマップは未保存である．

評価範囲． 最終測定日に追加チャートや印刷を利用できず，独立最終評価から学習チャートの新規10回読取へ変更した．同一入力での方式差と読取変動を評価するが，未知色への汎化性能は検証していない．保存入力の実機再生は物理読取と分けて記録した．

6　結果

6.1　新規10回のMSE

表1　全10回のMSE集計

H	方式	平均MSE	標本SD	最小	最大	300以下の回数
40	DENSE	319.56	903.46	5.29	2889.14	9/10
40	CSR	452.04	923.64	112.70	3078.33	9/10
60	DENSE	238.33	738.23	1.22	2339.37	9/10
60	CSR	493.51	814.80	177.18	2811.55	9/10
80	DENSE	231.68	646.48	1.25	2069.25	9/10
80	CSR	465.72	683.36	202.44	2407.85	8/10
100	DENSE	260.42	643.68	2.44	2063.62	8/10
100	CSR	651.92	694.07	318.85	2576.07	0/10

平均MSE300以下はDenseのH60・80・100であった．CSRは全Hで平均300を超え，H100は全回で300を超えた．

7　本稿で省略した内容

対応差，モデル配列容量，推論時間，Flash・RAMの結果，考察，結論および各回の実測値は，完成版に掲載している．本稿はその一部を確認するための抜粋である．

8　参考文献

[1] R. Tibshirani, “Regression Shrinkage and Selection via the Lasso,” Journal of the Royal Statistical Society: Series B, 58(1), pp. 267–288, 1996.

[2] S. Han, J. Pool, J. Tran, and W. J. Dally, “Learning Both Weights and Connections for Efficient Neural Networks,” Advances in Neural Information Processing Systems 28, pp. 1135–1143, 2015.

[3] N. Bell and M. Garland, “Implementing Sparse Matrix-Vector Multiplication on Throughput-Oriented Processors,” Proceedings of SC ’09, Article 18, pp. 1–11, 2009.

[4] Arduino, “micros(),” Arduino Documentation, https://docs.arduino.cc/language-reference/en/functions/time/micros/.

[5] PyTorch Contributors, “SmoothL1Loss,” PyTorch Documentation, https://docs.pytorch.org/docs/stable/generated/torch.nn.SmoothL1Loss.html.